

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji

Kierunek: **Inżynieria Systemów (INS)**

PRACA DYPLOMOWA
INŻYNIERSKA

Moduł samouczący do systemu automatyki
domowej

Przemysław Grzegorz Barcicki

Opiekun pracy
dr. inż. Patryk Schauer

Słowa kluczowe: automatyzacja domowa, uczenie maszynowe, smart-home

WROCŁAW 2023

STRESZCZENIE

Tutaj sobie na razie zostawie lorem ipsum, streszczenie napisze pod koniec/później w trakcie pisania.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

ABSTRACT

Same as above c:

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

SPIS TREŚCI

1. Wstęp	2
1.1. Wprowadzenie do problematyki	2
1.2. Opis problemu	2
1.3. Cel pracy	3
1.4. Zakres pracy	3
2. Przegląd istniejących rozwiązań	4
2.1. Systemy korzystające z algorytmów wykrywania epizodów	4
2.2. Systemy korzystające z procesów Markowa	5
2.3. Sieci neuronowe	6
2.4. Podsumowanie i wnioski	6
3. Wymagania projektowe	8
4. Architektura	9
4.1. Architektura środowiska i narzędzia	9
4.1.1. HomeAssistant – HA	9
4.1.2. AppDaemon – AD	9
4.1.3. Python i Tensorflow - tf	10
4.1.4. Docker	10
4.1.5. Pozostałe narzędzia i biblioteki	11
4.1.6. Podsumowanie	11
4.2. Architektura modułu	12
4.2.1. Dane wejściowe i wyjściowe	12
4.2.2. Architektura głębokich sieci neuronowych	13
4.2.3. Eksport i import sieci	14
4.2.4. Podsumowanie	15
Podsumowanie	16
Bibliografia	17
Spis rysunków	18
Spis listingów	19
Spis tabel	20

1. WSTĘP

1.1. WPROWADZENIE DO PROBLEMATYKI

Automatyzacja to określenie na metody mające na celu ograniczenie ludzkiej interakcji do minimum w różnych procesach. Stosuje się ją w wielu dziedzinach począwszy na przemyśle, kończąc na procesach informatycznych. Pewnym jednym konkretnym obszarem zyskującym w ostatnim czasie dużo zainteresowania jest pojęcie inteligentnego domu (smart-home). Automatyka domowa to konkretne określenie na zastosowanie automatyzacji wśród urządzeń smart-home skupiających się na obszarze zastosowań gospodarstwa domowego. Celem takiego zastosowania jest kontrola pracy urządzeń znajdujących się w domu do osiągnięcia konkretnego ich stanu w sposób minimalizujący ludzką interakcję. W praktyce takie systemy to bardzo dobre rozwiązanie które niesie ze sobą wiele zalet i uproszczeń w codziennym życiu [12].

Zasada czy reguła w automatyce to w dokładny sposób określenie jakie akcje muszą zostać wykonane pod warunkiem pewnego stanu systemu. Warunkiem początkowym może być każdy stan dowolnego urządzenia w systemie, zmiana stanu dowolnego urządzenia lub całkowicie zewnętrznego bodźca. W przypadku takiej automatyzacji często też korzysta się z kombinacyjnego połączenia wielu źródeł i informacji w celu stworzenia stanu początkowego, który jeśli wystąpi, jest przesłanką do wysłania przez system zarządzający urządzeniami polecenia do wykonania pojedynczej lub ciągu akcji. Każde dostępne na rynku dedykowane oprogramowanie obsługujące automatykę domową dostarcza różne narzędzia do szybkiego i intuicyjnego sporządzania takich zasad ale także dostarcza sposoby na komunikację z tymi urządzeniami. Mamy zatem pełny system, który agreguje wiele systemów, protokołów i sposobów wymiany danych w celu monitorowania i sterowania urządzeniami w ramach (lokalnej) sieci.

1.2. OPIS PROBLEMU

Mimo tego, że analiza i projektowanie systemów inteligentnej automatyki domów zaczęła się kilka dekad temu, istnieje wiele nierozwiązanych problemów, które muszą zostać rozwiązane, aby taka forma stała się popularna. Problemami są nieprawidłowe algorytmy oraz niskie celności wynikowe [9].

Mimo wygody w używaniu i łatwości w sporządzaniu zasad automatyki domowych zastosowań pojawiają się pewne trudności. Jednym z nich jest problem ze zmiennością

ludzkich nawyków. Sporządzenie zasad sprawia, że dane czynności są wykonywane wtedy i tylko wtedy gdy zostanie spełniony pewien konkretny stan określony przez nas podczas sporządzania danej reguły. Z logicznego punktu widzenia jest to odpowiednia odpowiedź systemu, natomiast z tego praktycznego już nie, ponieważ dana reguła może zostać wykonana mimo tego, że nie chcieliśmy aby się wykonała. Dodaje to pewien wymóg dodatkowego komplikowania danej zasady poprzez dodatkowe warunki w systemie lub ciągle jej edytowanie aby odpowiadała naszym zmiennym nawykom.

Bez względu na to jakie narzędzia dostarcza nam dany system, sporządzanie dużej ilości skomplikowanych reguł może być problematyczne. Same środowiska zarządzania takimi systemami mimo wspierania tworzenia na tyle skomplikowanych zasad mogą nie być do tego przystosowane. Często zdarza się, że system automatyki udostępnia dodatkowe, jako wtyczki lub dodatki, moduły do tworzenia reguł za pomocą interpretowanych języków programowania [1], [13], [3]. Tworzy to natomiast zestaw innych problemów, gdzie użytkownik chcący stworzyć takie reguły, musi w przynajmniej podstawowy sposób znać języki języki programowania oraz dodatkowo w jaki sposób sporządzać te skrypty aby mogły być wykonywane przez oprogramowanie nadzorujące.

1.3. CEL PRACY

Celem niniejszej pracy jest opracowanie modułu do systemu automatyki domowej (smart-home) wspierającego tworzenie reguł decyzyjnych w oparciu o mechanizmy uczące się zachowań użytkownika.

1.4. ZAKRES PRACY

Zakres pracy obejmuje przegląd literatury w zakresie działania i budowy systemów wspomagania podejmowania decyzji podejmowania decyzji opartych o uczenie maszynowe.

2. PRZEGLĄD ISTNIEJĄCYCH ROZWIĄZAŃ

W tym rozdziale omówiono literaturę i istniejące rozwiązania problemu rozwiązywanego w dalszej części tej pracy. Pod uwagę brano prace, które korzystają z klasycznych metod uczenia maszynowego oraz metod zawierających elementy sieci neuronowych. Analizie zostaną poddane użyte algorytmy jak i podejścia do osiągnięcia celu wspomagania decyzji automatyki domowej.

2.1. SYSTEMY KORZYSTAJĄCE Z ALGORYTMÓW WYKRYWANIA EPIZODÓW

Episode Discovery (wykrywanie epizodów) to metoda data mining'u (kopania danych) wykorzystująca istniejący ciąg występujących po sobie wydarzeń do wykrywania w nich powtarzalnych znaczących epizodów. Wśród epizodów można wyróżnić, tak zwane, epizody znaczące, które według zależnych od algorytmu charakterystyk, określają dany epizod jako często występujący.

Często można spotkać się pewną interpretacją ciągu zdarzeń w systemie gdzie każda występująca po sobie w pewnym oknie czasowym akcja jest reprezentowana jako odpowiedni znak ze zbioru wybranych możliwych zdarzeń. W przypadku opisu stanu systemu za pomocą reprezentacji znakowej, korzysta się z metodyki, gdzie duża litera oznacza przejście stanu danego urządzenia w załączone, a mała litera oznacza wyłączenie. W przykładowych ciągach zdarzeń, baDgb, abD, Dagb. Można zauważyć, że zawsze po wystąpieniu wyłączenia urządzenia a, następuje wyłączenie urządzenia b. W rzeczywistości algorytmy są bardziej zaawansowane i wykrywają epizody znaczące które występują często, ale nie zawsze, ale także operują na dużo dłuższych łańcuchach zdarzeń.

Wykorzystywanie algorytmów wykrywania epizodów na zapisanych już strumieniach wydarzeń pozwala na znalezienie pewnych nawyków i zależności z codziennego korzystania z domowych urządzeń. Znalezione i wyodrębnione epizody mogą zostać użyte z innymi algorytmami w celu podniesienia ich celności. Tak przetworzone dane wejściowe z dodatkowym użyciem innego algorytmu dają zdecydowanie lepsze wyniki niż w wypadku użycia samych sieci neuronowych bądź samego wykrywania epizodów [4], [9].

Ważnym elementem wykorzystania technik wykrywania epizodów jest prawidłowy wybór algorytmu (SPADE, SPEED, WINEPI, ...) jak i jego hiperparametrów, ponieważ inne wartości parametrów wybierających epizod znaczący może mocno wpływać na końcowy wynik [9]. O ile w przypadku algorytmu, nieprawidłowy wybór może ograniczać się do

wydłużonego czasu poszukiwania epizodów, a co za tym idzie, większego zużycia energii przez system, tak w przypadku niewłaściwych parametrów, algorytm może proponować za dużo akcji i nawyków, które źle będą wpływały na końcowy wynik, co w końcu sprawi, że komfort korzystania z takiego systemu będzie mały.

Podjęcie wykrywania epizodów, jest metodą skupiającą się na pewnych ciągach zdarzeń, które nie biorą pod uwagę żadnych innych zewnętrznych parametrów. Sprawia to, że system uczy się ciągów wydarzeń bez względu na aktualny stan systemu, czyli na przykład porę dnia, temperaturę w pomieszczeniu, dzień tygodnia czy też pogodę. Połączenie klasycznych algorytmów episode discovery z dodatkowymi algorytmami które, biorą pod uwagę inne parametry systemu, rozwiązuje ten problem, ale dodaje dużo skomplikowania w implementacji.

Korzystanie z metody dużych i małych liter do oznaczania wyłączeń i włączeń urządzeń tworzy dodatkowo pewne ograniczenia w postaci braku lub bardzo skomplikowanej obsługi urządzeń o niebinarnych stanach. O ile w przypadku urządzeń gdzie stanów jest kilka, jak na przykład systemy HVAC, można każdy z trybów pracy zinterpretować jako inną czynność, tak w przypadku urządzeń gdzie istnieje teoretycznie nieskończenie wiele stanów pośrednich, tak jak na przykład w ściemniaczach żarówkowych, nie jest możliwe reprezentowanie każdego z nich.

2.2. SYSTEMY KORZYSTAJĄCE Z PROCESÓW MARKOWA

Podczas modelowania zmian stanu systemu automatyki domowej można skorzystać z podejścia gdzie próbujemy opisać ciąg zdarzeń za pomocą prawdopodobieństwa przejść między stanami. Bardzo pomocne w takim podejściu okazuje się korzystanie z modeli Markowa. Istnieje pewne rozszerzenie modeli, które okazuje się bardziej pomocne w wypadku modelowania ludzkiej interakcji i zachowań z powodu uwzględnienia niezależnych i nieznanymi przez system stanów, nazywanym ukrytym modelem Markowa. Czyste podejście z prawdopodobieństwem odpowiada na pytanie, jaka jest szansa na wykonanie akcji A pod warunkiem tego, że poprzednio wykonana akcja to B, dodatkowe ukryte informacje pomagają w dokładniejszym określeniu przewidywanego stanu systemu.

Podobnie jak w przypadku wykrywania epizodów (2.1) do wytworzenia reprezentacji zmian systemu wykorzystywany jest literowy zapis, co sprawia, że te podejścia mają takie same ograniczenia. Jedną z prac [15], próbuje rozwiązać problem związany z rzeczywistą (niebinarną) naturą pewnych stanów poprzez kwantyzację w konkretne stany. Konkretnie wartości temperaturowe zamieniane są na arbitralny identyfikator wskazujący na daną temperaturę, co używane jest w modelu jako jeden z parametrów.

Podjęcie znalezione w [15], próbuje także rozwiązać za pomocą autorskiej metody IHMM (Improved Hidden Markov Models) problem powiązania pewnych konkretnych nawyków i ciągów wydarzeń z pewną temporalną zmienną, co sprawia, że system podpo-

wiada konkretne akcje dokładniej o konkretnych porach dnia, lecz dalej nie rozwiązuje problemu rozpoznania np. dni tygodnia czy pogody na dworze.

Inna implementacja [2], korzysta z innego, również autorskiego rozwinięcia modeli markowa TMM (Task-based Markov Model), w której skupia się na zidentyfikowaniu wysokopoziomowych zadań, które to dalej są wykorzystywane do stworzenia pomniejszych modeli reprezentujących ciąg zdarzeń w konkretnym zadaniu. Zadania są identyfikowane na podstawie przerwy pomiędzy kolejnymi wydarzeniami oraz na podstawie dodatkowej informacji o lokalizacji danego urządzenia. Zadania wraz z informacjami o ilości, długości i położenia w przestrzeni używane są przez algorytm k-średnich do pogrupowania zadań i stworzenia zbioru konkretnych ciągów.

2.3. SIECI NEURONOWE

Często spotyka się w parze z innym algorytmem sieci neuronowe, ponieważ są w stanie poprawić zdecydowanie celność predykcji niskim kosztem [4]. Istnieją pewne rozwiązania, gdzie sieci neuronowe są głównym sposobem na przeprowadzania predykcji. Ich szerokie zastosowanie i wiele istniejących rozwiązań sprawia, że są w stanie występować na prawie każdej platformie obliczeniowej. Dodatkowo w ciągu ostatniej dekady widać było zdecydowany rozrost zastosowań i nowych rozwiązań korzystających w pewien sposób z głębokich sieci neuronowych.

Różne istniejące zastosowania i modele głębokich sieci neuronowych daje duże pole do ich zastosowań. W przypadku pracy autorstwa S. Umamageswari [14], zastosowano jedno z popularnych w ostatnim czasie rozwiązań LSTM (long short-term memory). Rekurencyjne sieci neuronowe korzystające z warstw LSTM są w stanie zauważać występujące w dużej odległości danych uczących po sobie pewne zależności. Jest to dobre zastosowanie dla sieci wykorzystujących dużą ilość danych wejściowych zawierające pewne informacje temporalne. Takie modele matematyczne w procesie propagacji wstecznej błędu, są w stanie "nauczyć" się ciągu konkretnych zadań wykonywanych o konkretnych porach dnia, prezentując systemowi przykładowe historyczne wystąpienia tych zadań [10].

Ciekawym podejściem okazuje się wykorzystanie konwolucyjnych sieci neuronowych w przypadku wprowadzania dodatkowych zmiennych do systemu [7]. System w celu określenia następnej akcji którą ma podjąć bierze pod uwagę wyraz twarzy użytkownika. Obraz twarzy, przekształcany jest przez sieci konwolucyjne do zestawu informacji mówiącym o samopoczuciu użytkownika.

2.4. PODSUMOWANIE I WNIOSKI

Biorąc pod uwagę przeprowadzoną analizę, widać, że wstępne przetwarzanie danych i odpowiednie ich spreparowanie jest bardzo kluczowe. Prawidłowa reprezentacja stanu w

systemie jest kluczowa, ponieważ to na podstawie tego system będzie przeprowadzał swoje predykcje. W przypadku tradycyjnych algorytmów uczenia maszynowego widać ich zdecydowane ograniczenia, których rozwiązanie wymaga zdecydowanego komplikowania problemu poprzez wprowadzanie kwantyzowanych informacji czy zmiennych reprezentujących wartości temporalne. Metodą dającą największą elastyczność okazuje się wykorzystanie głębokich sieci neuronowych, ze względu na ich możliwość, przy wcześniejszym odpowiednim przekształceniu wejścia lub wyjścia, wprowadzania danych o różnych formatach, czy sterowania szerokim zakresem różnych urządzeń.

3. WYMAGANIA PROJEKTOWE

Celem tego projektu jest wytworzenie systemu zdolnego do wspomagania użytkownika w eksploatacji inteligentnych urządzeń IoT znajdujących się w jego domowym środowisku poprzez wykonywanie pewnych czynności za użytkownika.

Automatyzacja nie powinna wykonywać się wprost, tj. bez ludzkiej interakcji. Użytkownik korzystający z tego systemu będzie spełniał kluczową rolę, ponieważ wymaga się, aby system dokończył powtarzalne ciągi zadań wykonywanych przez użytkownika.

Wymagane jest aby rozpoczęcie używania tego systemu wymagała od użytkownika minimum konfiguracji, system powinien pobierać dane z istniejącego już systemu automatyki domowej i używać ich w celu wytworzenia reguł. Dodatkowo, sam system powinien być niezależny od architektury komputera na którym się znajduje. Zaleca się, aby moduł współpracował z gotowymi systemy automatyki domowej. W wypadku utraty przez komputer obsługujący system prądu, system powinien wznowić swoją pracę bez ponownego procesu tworzenia reguł decyzyjnych.

Wymaga się, aby system nie wymagał dużej ilości prac w celu dodania nowych typów źródeł i typów ujęć danych, tak aby ewentualne dodawanie obsługi urządzeń dla których nie istnieje gotowe wsparcie było najprostsze. System powinien móc wykorzystywać dodatkowe źródła danych w celach predykcji.

W wypadku innej odpowiedzi systemu niż użytkownik oczekuje, użytkownik powinien mieć łatwy sposób na cofnięcie wykonania błędnej akcji do poprzedniego stanu.

Biorąc powyższe pod uwagę, można określić listę wymagań funkcjonalnych i нефunkcjonalnych tego systemu. Wymagania funkcjonalne:

- wspomaganie codziennej eksploatacji urządzeń w domu,
- cofanie akcji,
- odczyt oraz zapis do pamięci stałej,
- wsparcie istniejącego systemu automatyki,
- dodawanie innych źródeł danych,

Wymagania нефunkcjonalne:

- minimum konfiguracji,
- działanie niezależne od architektury komputera,
- łatwość w tworzeniu rozszerzeń,

4. ARCHITEKTURA

4.1. ARCHITEKTURA ŚRODOWISKA I NARZĘDZIA

Na tym stadium pracy bardzo ważne jest dokładne zbadanie wymogów znajdujących się w rozdziale (3), w celu odpowiedniego przygotowania architektury systemu. Błędny wybór, może skutkować ograniczeniami co do zastosowań tego systemu.


4.1.1. HomeAssistant – HA

Jako system automatyki domowej, kontrolujący wymianę informacji naszego modułu ze światem rzeczywistym wybrano platformę HomeAssistant. Jest to jeden z największych niekomercyjnych systemów tego typu. Jego przewagą w porównaniu do niektórych innych dostępnych na rynku systemów są rzesze fanów i majsterkowiczów, którzy oferują świetne wsparcie i pomagają w rozwiązywaniu problemów. HA skupia się także na prywatności. Programiści open-source jak i użytkownicy systemu zalecają utrzymywanie systemu na swojej własnej infrastrukturze w domu. Dzięki wiernym fanom i samej architekturze projektu system posiada bardzo bogatą bibliotekę integracji z różnymi systemami, od systemów typu Google Assistant w celu dodawania funkcjonalności sterowania głosem, przez własnościowe systemy zarządzania oświetleniem w domu aż po wsparcie dodatkowych bezprzewodowych protokołów komunikacyjnych przeznaczonych do zastosowań domowych. Bardzo ważnym atutem poza szerokim polem różnych integracji jest także system rozszerzeń, gdzie użytkownik może dodać pewną kompletnie nieistniejącą w systemie funkcjonalność do poprawy działania systemu, czy automatyzacji innych rzeczy niezwiązanych z domem.

Na obrazie (4.1) znajduje się dostępne na stronie internetowej demo interfejsu mające na celu pokazanie użytkownikom możliwości całego systemu, ale także sposoby komponowania przykładowego panelu zarządzania domem.

4.1.2. AppDaemon – AD

System pozwalający stworzenie modułu samouczącego powinien dawać maksimum możliwości i niezależności, zatem wybrano AppDaemon. AppDaemon to środowisko wykonawczego Pythona, w wielowątkowej architekturze piaskownicy, służące do pisania aplikacji automatyzacji dla projektów automatyki domowej (i nie tylko), których wymogiem jest solidna architektura sterowana zdarzeniami. AD jest od razu gotowe do współpracy z systemem HomeAssistant, co sprawia, że integracja systemów HA/AD jest bezproblemowa.



Rys. 4.1. Przykładowy panel sterowania domem dostarczony przez HomeAssistant

System pozwala natychmiastowo reagować na zmiany stanów urządzeń znajdujących się w domowym środowisku, poprzez korzystanie z asynchronicznej architektury callback.


4.1.3. Python i Tensorflow - tf

Wykorzystanie struktury HA/AD ogranicza nas do wyboru Pythona jako przewodniego języka programowania w tym przedsięwzięciu. Wybór tego języka nie jest jednak ograniczeniem w tym projekcie, ponieważ posiada on bardzo wielką rzeszę fanów tworzących i udoskonalających paczki kodu dodające nowe możliwości w celu powiększenia pola zastosowań tego języka.

Konkretnym jednym zastosowaniem, który w ostatnim czasie budzi wiele uwagi, jest zastosowanie języka Python do celów uczenia maszynowego. Jedną z bibliotek dostarczających rozwiązania związane z tworzeniem, "uczeniem" i eksploatacją modeli różnego rodzaju sieci neuronowych jest paczka Tensorflow. Tf implementuje wiele gotowych modeli i algorytmów przyspieszających tworzenie modeli sieci neuronowych. Dodatkowo w celu przyspieszenia procesu liczenia błędu propagacji, biblioteka korzysta z różnego rodzaju akceleratorów obliczeń, w tym kart graficznych.

4.1.4. Docker

Ze względu na wymóg niezależności od platformy na jakiej będzie znajdować się ten system, zdecydowano o wyborze jako jednej z głównych technologii, systemu Docker w celu zapewnienia aplikacjom pracującym pod nim odpowiednich warunków niezależnie od systemu operacyjnego na jakim się znajdują. Dodatkowym powodem, który sprawił że



Rys. 4.2. Proponowane środowisko rozwiązania problemu.

wybrano tą technologię jest gotowe wsparcie systemów HA i AD do pracy w konteneryzowanym środowisku bez dużej ilości konfiguracji. Gotowe obrazy aplikacji znajdują się w sieci, a ich instalacja pod warunkiem posiadania środowiska Docker jest bardzo prosta i szybka.

Dodatkowo narzędzia które dostarcza Docker, pozwalają na tworzenie własnych kontenerów i udostępnianie ich innym co sprawi, że nie będzie to rozwiązanie przygotowywane specjalnie pod konkretne środowisko automatyki.

4.1.5. Pozostałe narzędzia i biblioteki

W celu zarządzania środowiskiem programistycznym, wykorzystano platformę Pipenv, która to ułatwia zarządzanie wirtualnymi środowiskami języka Python oraz ułatwia instalację wszystkich bibliotek potrzebnych w danej bazie kodu. Aby wytworzyć gotową paczkę kodu która dalej, która zostanie zainstalowana w AD, wykorzystano narzędzie `setuptools`. Do wszelakich numerycznych obliczeń oraz interfejsu z Tensorflow została wykorzystana biblioteka `numpy`. Automatyzowanie środowiska programistycznego zostało wykonane za pośrednictwem `Makefile`.

4.1.6. Podsumowanie

Na obrazie (4.2) znajduje się zaproponowana architektura wysokopoziomowa środowiska. Urządzenia automatyki znajdujące się w domowym środowisku będą komunikowały się z HomeAssistant w celu aktualizowania swojego stanu, ten będzie przesyłany dalej do AppDaemon gdzie będzie znajdował się nasz moduł obsługujący wybrane zdarzenia. Korzystając z informacji o zdarzeniu, system będzie przewidywał następną akcję i wykonywał pozostałą przewidzianą w danym epizodzie zmianę stanu. Informację o poleceniu zmiany stanu będzie obsługiwał AD, który to dalej będzie przysyłał tą informację do HA, który zdecyduje jak z danym urządzeniem się skomunikować i jaką wiadomość wysłać.

Wewnątrz bloku z modułem samouczącym znajdzie się dopiero kod napisany w języku Python, który będzie reagował na zmiany stanu i w odpowiedni sposób go preparował do przekazania modelowi sieci neuronowych a następnie przekształcany do formy umożliwiającej sterowanie urządzeniami w domu.

4.2. ARCHITEKTURA MODUŁU

Ze względu na wymóg obsługi różnych typów urządzeń oraz źródeł danych, bardzo ważnym aspektem do zaprojektowania jest struktura systemu tłumaczącego dane na takie które, zrozumie biblioteka Tensorflow, zaprojektowanie samych modeli głębokich sieci neuronowych, ale także tłumaczenie wygenerowanej przez model odpowiedzi do takiej, którą zinterpretuje reszta modułu.

4.2.1. Dane wejściowe i wyjściowe

System zarządzania automatyką domową podczas swojej pracy zbiera informacje na temat zmian stanów urządzeń którymi steruje i zapisuje je w lokalnej bazie danych. Nie jest ona jednak dostępna w łatwy sposób dla programisty. AppDaemon w swoim interfejsie programistycznym udostępnia możliwość ściągnięcia historii zmian wybranego urządzenia z ostatniego czasu. Dane przekazane z zapytania do aplikacji są w postaci listy słowników języka Python o strukturze zawartej w listingu (4.1). Słownik to pewna struktura danych w której informacja jest zawarta w wartościach dla konkretnego klucza [6].

```
[
  {
    "entity_id": "input_boolean.test_switch_1",
    "state": "off",
    "attributes": {
      "icon": "mdi:lightbulb-on-outline",
      "friendly_name": "Testowy przelacznik 1"
    },
    "last_changed": "2023-11-15T13:07:52.856406+00:00",
    "last_updated": "2023-11-15T13:07:52.856406+00:00"
  },
  ...
]
```

Listing 4.1: Historyczne informacje na temat stanu urządzenia pochodzące z systemu AppDaemon.

Warto zauważyć, że informacja zawarta w polu `state`, ma inne znaczenie w zależności od typu urządzenia czy źródła. W przypadku urządzenia typu przerzutnik stabilny o binarnych pozycjach, dane w kluczach `state` oraz `last_changed` wskazuje na czas kiedy

zaszła zmiana do jakiego stanu, a w przypadku zwykłego przycisku, wystarcza samo pole ze stanem, ponieważ znajduje się tam czas ostatniej zmiany.

W celu zaspokojenia integracji z wieloma urządzeniami system powinien na podstawie dostarczonej mu informacji o typie urządzenia tłumaczyć ciąg historycznych zmian na dane treningowe do modelu sieci. Aby rozszerzenie tego rozwiązania było możliwe przez użytkownika, proponuje się, aby system korzystał z klas abstrakcyjnych. Pozwoli to na stworzenie bazowego obiektu i funkcji jakie powinno obsługiwać dane urządzenie w celu współpracy z modułem [8]. Dodatkowo wymusi to na użytkowniku tworzącym dodatkowe elementy, stworzenie wszystkich wymaganych funkcji, a nie jej pewnej części, co pomaga w redukcji błędów programistycznych.

W celu odpowiedniego przygotowania danych wyjściowych pochodzących z sieci neuronowej, można skorzystać z zaproponowanego wyżej kodu obsługującego dane wejściowe poprzez stworzenie dodatkowych funkcji obsługujących przemiane danych.

Proponowana struktura danych na której moduł będzie się opierał to zestaw dwóch macierzy (4.1). Pierwsza zawierająca informacje o aktualnym stanie systemu składająca się z u informacji wejściowych nazywana macierzą stanu, druga składająca się z w skalarów opisująca zmiany w stanach nazywana macierzą przejścia.

$$\begin{aligned} \mathbf{S}_t &= [s_1, s_2, \dots, s_u] \\ \mathbf{Z}_t &= [z_1, z_2, \dots, z_w] \end{aligned} \tag{4.1}$$

Pierwsza z nich opisuje stan środowiska domowego w danym momencie t , druga z nich wskazuje na zmianę stanu urządzeń do następnego momentu w czasie $t + 1$. Jesteśmy w stanie określić pewną funkcję G w zależności od typów urządzeń i źródeł, która na podstawie aktualnego stanu oraz zmiany w danym momencie, generuje nam następną macierz \mathbf{S}_{t+1} (4.2).

$$G(\mathbf{S}_t, \mathbf{Z}_t) = \mathbf{S}_{t+1} \tag{4.2}$$

$$\mathbf{Z}_t = P(\mathbf{S}_t) \tag{4.3}$$

Biorąc powyższe pod uwagę, proponowane rozwiązanie powinno na podstawie macierzy stanu \mathbf{S} w momencie k przewidywać następny zestaw ruchów użytkownika, czyli macierz przejścia \mathbf{Z} dla tego samego momentu w czasie (4.3).

4.2.2. Architektura głębokich sieci neuronowych

Sercem pracy całego modułu są modele matematyczne sieci neuronowych. Ze względu na wymóg minimalnej konfiguracji, ich logiczna konfiguracja, powinna być wybrana tak, aby były w stanie nauczyć się epizodów akcji użytkownika bez zbędnej wielkości i

Tabela 4.1. Tabela zawierająca listowanie warstw w pojedynczej sieci neuronowej

Warstwa	Aktywacja	Ilość neuronów
0	linear	Zależna od ilości urządzeń
1	ReLU	128
2	ReLU	64
3	tanh	1

skomplikowania. Dodatkowym powodem ograniczenia skomplikowania takich sieci jest zdecydowane wydłużenie procesu uczenia sieci neuronowych dla tych które, zawierają dużo wag [11].

Model sieci neuronowej zawarty w takim module będzie pracował z różnymi typami urządzeń wejściowych gdzie dane będą sformatowane w różny sposób, dodatkowo dane wyjściowe będą musiały być interpretowane przez moduł inaczej, w zależności od celu. Tworzenie dużych i skomplikowanych sieci nie zawsze sprawia, że jest ona w stanie lepiej nauczyć się przekazywanych jej danych ze względu na klątwę wymiarowości [5].

Biorąc powyższe pod uwagę, proponuje się, aby moduł podczas tworzenia początkowych modeli nie tworzył jednej monolitycznej sieci odpowiedzialnej za wszystkie wejścia i wyjścia, a tworzył tyle sieci, ile jest urządzeń do sterowania. Umożliwi to sieciom lepsze dostosowanie się do urządzeń i natury ich używania kosztem lekko dłuższego czasu uczenia.


Proponowana struktura takich sieci znajduje się w tabeli (4.1). Pierwsza warstwa w tym modelu będzie zależna od ilości urządzeń i źródeł dodatkowych danych, a ostatnia warstwa będzie zawierała jedno wyjście. Taka struktura, będzie agregowała wszystkie wyjścia do jednej formy dostarczanej reszcie komponentów.

4.2.3. Eksport i import sieci

Aby móc zapisać modele sieci neuronowych, wszystkie części systemu mające z nimi styczność muszą wspierać takie działanie. W szczególności dwoma krytycznymi elementami w przypadku tego modułu samouczącego jest biblioteka Tensorflow oraz tworzony przez nas system konwersji danych. Oba te elementy powinny współpracować ze sobą na tyle dynamicznie, aby różne konfiguracje modeli oraz danych wejściowych były poprawnie obsługiwane.

W celu eksportu i importu sieci zostanie zaproponowany teoretycznie autorski sposób serializowania i deserializowania danych w którym wszystkie definicje oraz – równie ważne – wagi wyuczonych sieci neuronowych zostaną zapisane w odpowiednim formacie do pliku archiwum .zip. Proponowana architektura plików wewnątrz archiwum dla każdego z sieci osobno będzie składała się z:

1. Surowej deklaracji modelu, w której znajdzie się dokładny opis kształtu i wymiarów każdej z warstw potrzebnej do dokładnego jej odtworzenia.
2. Pliku z zapisanymi wagami każdej warstwy w sieci.



Rys. 4.3. Proponowana struktura działania modułu.

3. Pliku z informacjami pośrednimi, które nie są krytyczne do działania systemu.

Dodatkowo w celu określenia czy nie doszło do zmiany dostępnych dla systemu urządzeń oraz w celu zapisania innych informacji ogólnych o wszystkich dostępnych w modelu sieciach będzie potrzebny jeden dodatkowy plik znajdujący się katalogu głównym archiwum.

4.2.4. Podsumowanie

Na rysunku (4.3) znajduje się proponowana struktura całego modułu samouczącego. Dane o stanie i zmianach będą przechodziły strumieniem wgląd systemu gdzie dalej po obliczonej predykcji na jej podstawie, system będzie sterował urządzeniami w środowisku domowym.

PODSUMOWANIE

Curabitur tellus magna, porttitor a, commodo a, commodo in, tortor. Donec interdum. Praesent scelerisque. Maecenas posuere sodales odio. Vivamus metus lacus, varius quis, imperdiet quis, rhoncus a, turpis. Etiam ligula arcu, elementum a, venenatis quis, sollicitudin sed, metus. Donec nunc pede, tincidunt in, venenatis vitae, faucibus vel, nibh. Pellentesque wisi. Nullam malesuada. Morbi ut tellus ut pede tincidunt porta. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam congue neque id dolor.

BIBLIOGRAFIA

- [1] Cockburn, A., *Dokumentacja appdaemon*.
- [2] Cook, D.J., Youngblood, M., Heierman, E.O., Gopalratnam, K., Rao, S., Litvin, A., Khawaja, F., *Mavhome: An agent-based smart home*, w: *Proceedings of the First IEEE International Conference on Pervasive Computing and Communications, 2003.(PerCom 2003)*. (IEEE, 2003), str. 521–524.
- [3] openHAB Community openHAB Foundation, *Dokumentacja pisania skryptów*.
- [4] Heierman, E., Cook, D., *Improving home automation by discovering regularly occurring device usage patterns*, w: *Third IEEE International Conference on Data Mining (2003)*, str. 537–540.
- [5] Keogh, E., Mueen, A., *Curse of Dimensionality* (Springer US, Boston, MA, 2010), str. 257–258.
- [6] Lutz, M., *Learning Python* (O'REILLY', 2013).
- [7] Majeed, R., Abdullah, N.A., Ashraf, I., Zikria, Y.B., Mushtaq, M.F., Umer, M., *An intelligent, secure, and smart home automation system*, Scientific Programming. 2020, tom 2020, str. 4579291.
- [8] Martin, R.C., *Czysty Kod* (Helion, 2014).
- [9] Marufuzzaman, M., Tumbraegel, T., Rahman, L.F., Sidek, L.M., *A machine learning approach to predict the activity of smart home inhabitant*, J. Ambient Intell. Smart Environ. 2021, tom 13, 4, str. 271–283.
- [10] Pang, B., Nijkamp, E., Wu, Y.N., *Deep learning with tensorflow: A review*, Journal of Educational and Behavioral Statistics. 2020, tom 45, 2, str. 227–248.
- [11] Shah, B., Bhavsar, H., *Time complexity in deep learning models*, Procedia Computer Science. 2022, tom 215, str. 202–210. 4th International Conference on Innovative Data Communication Technology and Application.
- [12] Szablowski, S., *Projektowanie dydaktycznych systemów automatyki domowej*, Dydaktyka informatyki. 2019, , 14, str. 137–146.
- [13] Team, D., *Dokumentacja pisania skryptów domoticz.*
- [14] Umamageswari, S.S.M., Kannan, M.K.J., *Tensorflow-based smart home using semi-supervised deep learning with context-awareness*, Journal of Mathematical and Computational Science. 2022.
- [15] Wu, E., Zhang, P., Lu, T., Gu, H., Gu, N., *Behavior prediction using an improved hidden markov model to support people with disabilities in smart homes*, w: *2016 IEEE 20th International Conference on Computer Supported Cooperative Work in Design (CSCWD) (2016)*, str. 560–565.

SPIS RYSUNKÓW

4.1.	Przykładowy panel sterowania domem dostarczony przez HomeAssistant	10
4.2.	Proponowane środowisko rozwiązania problemu.	11
4.3.	Proponowana struktura działania modułu.	15

SPIS LISTINGÓW

4.1	Historyczne informacje na temat stanu urządzenia pochodzące z systemu AppDaemon.	12
-----	---	----

SPIS TABEL

4.1. Tabela zawierająca listowanie warstw w pojedynczej sieci neuronowej	14
--	----